

Исследование методов машинного обучения для определения устойчивости энергосистемы

Содержание

1 АНАЛИЗ МЕТОДОВ РАСЧЕТА СТАТИЧЕСКОЙ УСТОЙЧИВОСТИ РЕЖИМОВ ЭЭС И ИХ ПРИМЕНЕНИЯ.....	7
1 Традиционные методы анализа статической устойчивости и их применение.....	7
1 Методы анализа и критерии статической устойчивости.....	7
2 Анализ статической устойчивости на практике.....	10
2 Методы анализа устойчивости основанные на синхронизированных векторных измерениях.....	13
1 Метод основанный на матрице собственных и взаимных проводимостей.....	15
2 МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ И ИХ ИСПОЛЬЗОВАНИЕ В ЭЛЕКТРОЭНЕРГЕТИКЕ.....	17
1 Ансамблевые методы машинного обучения.....	18
1 Бэггинг и случайные леса.....	18
2 Бустинг (Boosting).....	19
2 Искусственные нейронные сети.....	20
1 Компоненты нейронных сетей.....	22
3 Машинное обучение в электроэнергетике.....	24
3 МОДЕЛИРОВАНИЕ ЭЭС ДЛЯ ИССЛЕДОВАНИЯ.....	27
1 ПК Мустанг и моделирование простейшей схемы ЭЭС.....	28
1 Выбор параметров схемы и расчет режима.....	28
2 Моделирование возмущающего воздействия и регистрирование векторных параметров сети.....	29
4 ОБРАБОТКА РЕЗУЛЬТАТОВ МОДЕЛИРОВАНИЯ И ПОСТРОЕНИЕ МОДЕЛЕЙ.....	34
2 Обработка данных.....	34
1 Подготовка данных.....	34
2 Преобразование данных и извлечение признаков.....	37

3 Выбор метрик оценки и построение моделей.....	40
1 Выбор метрик.....	41
2 Обучение моделей на табличных данных.....	43
3 Обучение моделей на сырых данных.....	53
5 ВЛИЯНИЕ НЕУСТОЙЧИВОСТИ СИСТЕМЫ НА ЦЕНУ В ОТДЕЛЬНЫХ УЗЛАХ.....	59
2 Формирование узловых цен в ЕНЭС.....	59
ВЫВОДЫ.....	61

ВВЕДЕНИЕ

Статическая устойчивость – это способность системы восстанавливать исходное или близкое к исходному состояние после незначительных возмущений.

Используемые в настоящее время методы для расчета статической устойчивости требуют постоянной актуализации параметров схемы ЭЭС, что является трудозатратным и нецелесообразным для ЭЭС с распределенной генерацией. Развитие малой генерации и систем измерения режимных параметров требует исследования и поиска новых алгоритмов и методов, которые будут использовать как можно больше параметров и производить анализ ЭЭС в реальном времени.

Основной целью магистерской диссертации является исследование возможности применения методов машинного обучения для определения значения статической устойчивости ЭЭС и поиск оптимального метода для классификации режима по значению коэффициента запаса статической устойчивости по активной мощности (послеаварийный/вынужденный/нормальный). После выбора наилучшего метода машинного обучения и его оценки произведена оценка стоимости внедрения разработанных технологий и их экономический эффект.

АКТУАЛЬНОСТЬ ТЕМЫ

В настоящее время наблюдается тенденция к децентрализации генерации и потребления электроэнергии, данная тенденция обусловлена следующими причинами:

- Высокий тариф на технологическое присоединение
- Либерализация рынка электроэнергии
- Снижение стоимости генерирующего оборудования, как ВИЭ, так и традиционных источников (газовое и дизельное генерирующее оборудование)

Распределенная генерация в России и СНГ представлена в основном когенерацией (синхронная генерация) с использованием различных видов топлива, в том числе ГЭС.

По причине децентрализации генерирующего и потребляющего оборудования наблюдается существенное изменение схемно-режимных свойств ЭЭС, которое приводит к изменению подробной модели ЭЭС. Цифровая модель ЭЭС не может быть актуализирована каждый раз при незначительных изменениях топологии сети или ее параметров, так как построение подробной модели требует значительных трудозатрат и является нетривиальной задачей.

Нецелесообразность применения традиционных методов и технологий расчета в электрических сетях с распределенной генерацией делает актуальным разработку и исследование альтернативных методов расчета режимных параметров, в данном случае статической устойчивости, что позволит в дальнейшем разработать комплекс новых технологий для использования в системах с распределенной генерацией.

Развитие современных систем измерения и регистрации режимных параметров дает техническую возможность для разработки и внедрения такой технологии. Синхронизированные векторные измерения позволяют получать модели для учета ограничений по устойчивости режима ЭЭС в задачах

оперативного и автоматического противоаварийного управления, соответствующие текущим режимам сети, без их полного контроля [4].

1 АНАЛИЗ МЕТОДОВ РАСЧЕТА СТАТИЧЕСКОЙ УСТОЙЧИВОСТИ РЕЖИМОВ ЭЭС И ИХ ПРИМЕНЕНИЯ

Статическая устойчивость – это способность системы восстанавливать исходное или близкое к исходному состояние после незначительных возмущений.

Контроль ограничений по статической устойчивости необходим в протяженных распределительных сетях с учетом происходящих изменений конфигурации в нормальных и послеаварийных режимах, когда предел передаваемой мощности может быть снижен за счет отключения параллельных элементов или увеличения длины участков сети между точками подключения распределенной генерации, а также в режимах максимальных нагрузок при ограничениях генераторов на выдачу реактивной мощности [3].

Методы рассматриваемые в данной главе методы можно разделить на две группы:

1. Традиционные – основанные на методе малых колебаний, определение устойчивости режима ЭЭС исходя из необходимых и достаточных условий устойчивости [5-6].
2. Экспериментальные – методы, основанные на векторных измерениях и современных достижениях в области измерения режимных параметров (синхронизированные векторные измерения).

Далее в этой главе будут подробнее рассмотрены вышеописанные методы и изложена проблема, по причине которой разработка новых методов является актуальной.

1 Традиционные методы анализа статической устойчивости и их применение

1 Методы анализа и критерии статической устойчивости

Традиционные методы исследования устойчивости электрических систем базируются на известных классических положениях общей теории устойчивости движения [1]. Статическая устойчивость электрических систем исследуется на основе методов, которые базируются на анализе дифференциальных уравнений первого (линейного) приближения [1,5,6].

Уравнение лежащее в основе анализа статической устойчивости — уравнение движения ротора генератора:

$$T_j * d^2(\delta)/dt^2 = P_t - P_g \quad (1.1)$$

где $T_j \dots$

При исследовании многомашинной ЭЭС уравнение движения ротора (1.1) выписывается для каждой машины и полученные уравнения составляют основную часть системы дифференциальных уравнений. Помимо уравнений движения ротора система также дополняется следующими уравнениями:

- уравнения описывающие переходные процессы в системах регулирования,
- алгебраические уравнения баланса напряжений и токов в электрической сети.

После линеаризации системы уравнений в точке положения равновесия возможно получение характеристического уравнения в виде:

характеристическое уравнение

После получения характеристического уравнения формируются критерии устойчивости (Рисунок 1.1) [4].

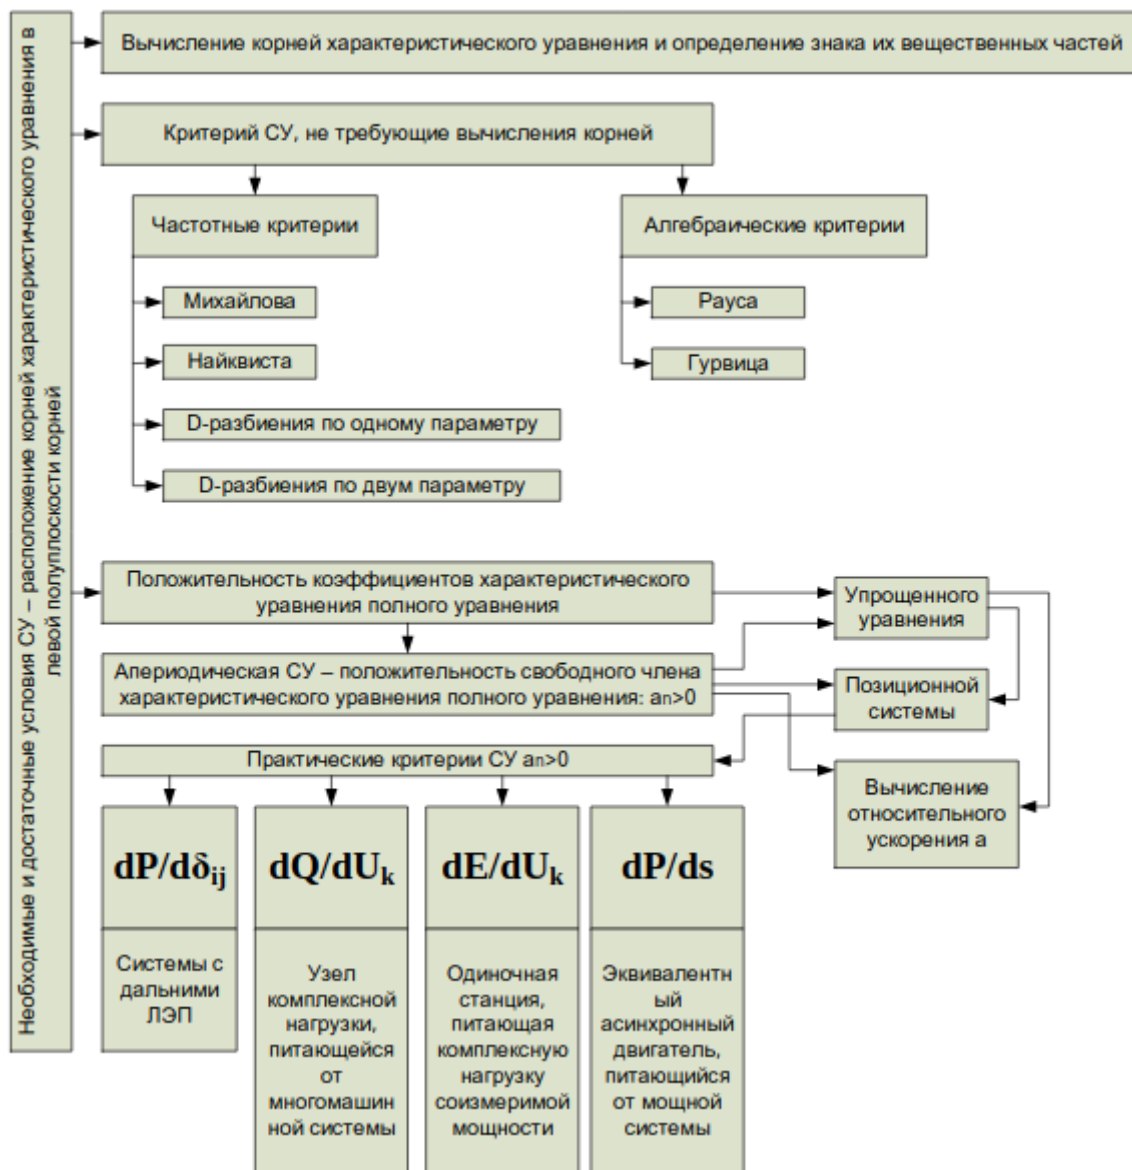


Рисунок 1.1 — Традиционные методы исследования статической устойчивости [4].

По причине того, что с применением традиционных методов для анализа статической устойчивости требуется расчет с учетом полной размерности задачи, которая резко возрастает с увеличением количества учитываемых элементов системы, что влечет за собой значительные вычислительные затраты и получаемый ответ говорит лишь о характеристике системы с точки зрения устойчивости (устойчива/неустойчива) они не удобны для управления ЭЭС [1,5].

Требования по устойчивости ЭЭС определены в методических указаниях «СО ЭЭС» [7]. В соответствии с требованиями нормируются минимально допустимые коэффициенты запаса статической устойчивости по напряжению в

узлах нагрузки и активной мощности, также устанавливаются группы возмущений, при возникновении которых должны обеспечиваться нормируемые коэффициенты запаса статической устойчивости в послеаварийных режимах.

Коэффициент запаса статической устойчивости по активной мощности K_p характеризует запас, допустимый по загрузке генератора относительно предельно-допустимой мощности и нормируется для нормальных (20%) и послеаварийных режимов (8%) с учетом нерегулярных колебаний [7]. Для расчета коэффициента запаса статической устойчивости по активной мощности используется следующая формула:

$$K_p (1.3)$$

где P_p — предельно допустимая мощность для сечения.

Коэффициент запаса по напряжению в узле нагрузки K_u определяется относительно критического напряжения в конкретном узле нагрузки и соответствует границе статической устойчивости электродвигателей. При отсутствии точного значения границы статической устойчивости узла нагрузки, он принимается равным $0,7 \cdot U_{ном}$, где $U_{ном}$ — номинальное напряжение в узле нагрузки.

Значения критериев для различных режимов в соответствии с методическими указаниями приведены в таблице 1.1.

Таблица 1.1 — Минимальные значения показателей устойчивости

Режим	K_p	K_u
Нормальный	0,2	0,15
Вынужденный/Аварийный	0,2	0,15

2 Анализ статической устойчивости на практике

В общем виде методика оценки режимной надежности ЭЭС состоит из следующих основных этапов:

1. формирование расчетной схемы (модели) ЭЭС
2. формирование списка возможных возмущений (состояний) ЭЭС
3. анализ режимов сформированных состояний ЭЭС
4. анализ чувствительности сети к возмущению и формирование дополнительных возмущений
5. вычисление показателей режимной надежности ЭЭС

Как правило, расчетная модель ЭЭС формируется на основе имеющегося в энергосистемах описания оборудования. В задачах моделирования ЭЭС используется модель узлы/ветви, для получения которой на основе реальных данных применяется топологический процессор. Причем следует отметить, что упрощение модели выполняется без потери точности за счет исключения связей с нулевым сопротивлением. Кроме того, упрощенная модель узлы/ветви не содержит ветвей с сопротивлением, близким к нулю. Тем самым улучшается сходимость процесса расчета установившегося режима.

Исходная (полная) оперативная схема ЭЭС формируется до использования программного комплекса оценки режимной надежности ЭЭС. В оперативном режиме с использованием системы SCADA или WAMS на основе измерений и оценки состояния формируются исходные данные по текущему режиму ЭЭС. Сведения по аварийности оборудования собираются в базу данных, характерную для рассматриваемой ЭЭС, и обрабатываются для использования в модели оценки надежности.

Статическая устойчивость режима определяется анализом корней характеристического уравнения или методом утяжеления. На практике чаще применяется метод утяжеления, так как, методы, основанные на анализе корней характеристического уравнения, требуют наличия точных данных по элементам сети. Кроме того, метод утяжеления может быть оптимизирован для анализа надежности таким образом, что начальным режимом для каждого аварийного события может быть наиболее близкий установившийся режим из уже рассчитанных. При этом траектория утяжеления определяется отличиями анализируемых аварийных ситуаций. Переходный процесс моделируется при

отключении элементов сети, если установившийся режим устойчив. Дополнительным критерием является близость к границе устойчивости, полученная на предыдущем шаге.

Пример алгоритма по расчету режимной надежности, на примере программно-вычислительного-комплекса АНАРЭС-2000, приведен на рисунке 1.2.



Рисунок 1.2 — Блок-схема программно-информационного пакета для расчета и анализа режимной надежности ЭЭС, реализованной в составе программно-вычислительного комплекса АНАРЭС-2000 [4].

Как отмечалось выше, методы полного моделирования включают численное решение систем нелинейных дифференциальных и алгебраических уравнений переходных процессов с детальным представлением системы для всех значимых нарушений режима ЭЭС. Из-за комбинаторной природы проблемы эти подходы требуют большого времени вычислений и постоянной актуализации модели ЭЭС. Чтобы уменьшить вычислительные затраты при решении этой задачи, большинство систем диспетчерского управления используют один или несколько индикаторов оценки устойчивости.

Кроме того, для оперативного анализа режимной надежности ЭЭС возможно применение экспресс-методов оценки режимной надежности,

которые не требуют явного моделирования поведения энергосистемы. Все методы экспресс-анализа устойчивости и надежности строятся по принципу выявления взаимосвязей изменения первичных параметров системы с опасными тенденциями. Именно подобным экспресс-методам и посвящена данная работа, а именно исследованию возможности использования алгоритмов машинного обучения в качестве экспресс методов.

2 Методы анализа устойчивости основанные на синхронизированных векторных измерениях

Благодаря созданию и развитию в ЕЭС России технологии СВИ появились более качественные данные о параметрах электрического режима энергосистемы и созданы предпосылки для совершенствования технологических алгоритмов работы систем мониторинга, защиты и управления и развития EMS-приложения на современной информационной платформе [9].

Измерения WAMS [8] позволяют получить согласованные измерения сразу по всей сети. Такой подход позволяет не просто повысить точность моделирования ЭЭС, но и дает качественно новые возможности. С точки зрения оперативного анализа надежности измерения WAMS [8] позволяет без непосредственного моделирования определять близость системы к границе допустимости режима по критериям надежности. Такая технология, естественно, требует проведения моделирования, выполняемого в режиме офлайн, для построения границы допустимости режима.

Контроль критических углов измерений PMU по ЛЭП также позволяет реализовывать локальные комплексы ПА и контроля устойчивости. Поскольку для построения границ устойчивости в любом случае требуется моделирование системы, то использование WAMS для целей анализа устойчивости имеет смысл как дополнительный инструмент, который позволит быстро определять близость системы к границе устойчивости.

Аналогом WAMS в ЕЭС/ОЭС России является система мониторинга переходных режимов (СМПР), которая состоит из регистрирующих приборов, систем обмена информацией между концентраторами данных и центрами управления, а также средств обработки полученной информации.

По состоянию на 2015 г. в ЕЭС России введено в эксплуатацию 68 программно-технических комплексов СМПР, и 396 устройств PMU. Размещение PMU и PDC (Phasor Data Concentrator) в ЕЭС показано на рис. 1.3.




Рисунок 1.3. Размещение программно-технических комплексов (ПТК) СМПР в ЕЭС.

Предоставляемые СМПР данные качественно нового уровня уже доказали свою практическую ценность и во всё более возрастающем объеме используются для решения прикладных задач. Поэтому в настоящее время необходимость в развитии СМПР не вызывает сомнений. В то же время СМПР — относительно новая технология, которая обладает уникальной совокупностью свойств и характеристик. Еще одной особенностью СМПР является использование при ее организации и функционировании самых

современных технологий, возможности которых еще не освоены в полном объеме и требуют изучения. Как следствие, потенциал всей структуры СМНР, даже уже существующий, не окончательно понятен и очевиден, что приводит к необходимости исследования и разработки новых методов для данных систем.

1 Метод основанный на матрице собственных и взаимных проводимостей

Альтернативной технологией, способной обеспечить допустимость нормальных и послеаварийных режимов по условию устойчивости параллельной работы синхронных машин в автоматическом режиме для электрической сети любой размерности, является технология контроля статической устойчивости режима электроэнергетической системы по данным СВИ, разработанная на кафедре АЭЭС НГТУ [3].

Для контроля статической устойчивости режима используется получаемая по данным регистрации параметров текущего режима модель ЭЭС, актуальная по структуре и значениям элементов, определяющая комплексные коэффициенты связи между ЭДС генераторов или их эквивалентных групп [3].

Основным недостатком данного метода является необходимость компромисса между точностью определения ограничений и временем получения результата, для чего используется фильтрация данных для формирования матрицы взаимных проводимостей.

Однако построение матрицы взаимных проводимостей актуальной схемы ЭЭС на базе СВИ является не единственным способом изучения статической устойчивости ЭЭС в реальном времени, и в этой работе будут исследованы различные алгоритмы машинного обучения для определения критерия устойчивости (коэффициента статического запаса по мощности K_p).

В данной главе были даны определения критериям статической устойчивости и рассмотрены классические методы расчета устойчивости режима. Описана технология СВИ, развитие которой опережает развитие инструментов, доступных для применения на базе векторных измерений. Рассмотрен недавно разработанный метод определения статической

устойчивости на базе векторных измерений с использованием матрицы взаимных проводимостей.

2 МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ И ИХ ИСПОЛЬЗОВАНИЕ В ЭЛЕКТРОЭНЕРГЕТИКЕ

Машинное обучение — обширный подраздел искусственного интеллекта, изучающий методы построения алгоритмов, способных обучаться. Различают два типа обучения (рис. 2.1). *Обучение по прецедентам*, или *индуктивное обучение*, основано на выявлении общих закономерностей по частным эмпирическим данным. *Дедуктивное обучение* предполагает формализацию знаний экспертов и их перенос в компьютер в виде базы знаний. Дедуктивное обучение принято относить к области экспертных систем, поэтому термины *машинное обучение* и *обучение по прецедентам* можно считать синонимами.



Рисунок 2.1 — Основные типы машинного обучения.

Машинное обучение находится на стыке математической статистики, методов оптимизации и классических математических дисциплин, но имеет также и собственную специфику, связанную с проблемами вычислительной эффективности и переобучения. Многие методы индуктивного обучения разрабатывались как альтернатива классическим статистическим подходам. Многие методы тесно связаны с извлечением информации и интеллектуальным анализом данных.

В данной работе будут исследованы алгоритмы машинного обучения с учителем, что подразумевает, что каждый пример данных, на основании которых будет производиться обучение, имеет только один правильный ответ, на основании которого и будет производиться обучение.

В настоящее время широкое применение в задачах прогнозирования получили методы:

- ансамблевые методы:
 - Случайный лес (Random Forest)
 - Градиентный бустинг
- нейронные сети (в том числе глубокое обучение)

1 Ансамблевые методы машинного обучения

Тема ансамблевых методов хорошо известна в машинном обучении и получила распространение в решении практических задач прогнозирования. Подобные системы имеют различные названия в разных источниках: смесь экспертов, ансамбли классификаторов, смесь классификаторов и прочие.

В основе всех подобных систем лежит идея обучения нескольких (простых) моделей на одной и той же обучающей выборке и комбинации их предсказаний для новых тестируемых объектов [11]. Математическим обоснованием идеи ансамблевых методов является теорема Кондорсье о жури и присяжных, впервые изложенная еще в 18 веке. Согласно теореме, если каждый присяжный в среднем вероятнее всего судит о виновности обвиняемого верно, нежели ошибочно, то вердикт большинства заслуживает доверия. В пределе, при количестве присяжных стремящемся к бесконечности, вероятность того, что большинство присяжных проголосует верно стремится к 1. Таким образом, имея несколько слабых классификаторов (ошибка классификации менее 50%), можно объединить их предсказания и достичь более высокой точности классификации объектов из тестовой выборки.

Среди самых распространенных ансамблевых методов в этой работе будут проверены бэггинг (bagging), случайные леса (random forest) и бустинг (boosting).

1 Бэггинг и случайные леса

Бэггинг - от англ. *Bootstrap aggregating*, это технология классификации, использующая композиции алгоритмов, каждый из которых обучается независимо. Результат классификации определяется путем голосования. Бэггинг позволяет снизить процент ошибки классификации в случае, когда высока дисперсия ошибки базового метода.

Бэггинг – технология классификации, где в отличие от бустинга все элементарные классификаторы обучаются и работают параллельно (независимо друг от друга). Идея заключается в том, что классификаторы не исправляют ошибки друг друга, а компенсируют их при голосовании. Базовые классификаторы должны быть независимыми, это могут быть классификаторы основанные на разных группах методов или же обученные на независимых наборах данных. Во втором случае можно использовать один и тот же метод.

Метод случайных лесов основан на бэггинге над решающими деревьями, бэггинг сильнее уменьшает дисперсию базовых алгоритмов, если они слабо коррелированы. В случайных лесах корреляция между деревьями понижается путем рандомизации по двум направлениям: по объектам и по признакам. Во-первых, каждое дерево обучается по бутстрапированной подвыборке. Во-вторых, в каждой вершине разбиение ищется по подмножеству признаков.

При построении дерева последовательно происходит разделение вершин до тех пор, пока не будет достигнуто идеальное качество на обучении. Каждая вершина разбивает выборку по одному из признаков относительно некоторого порога. В случайных лесах признак, по которому производится разбиение, выбирается не из всех возможных признаков, а лишь из их случайного подмножества размера m .

Случайные леса — один из самых сильных методов построения композиций. На практике он может работать немного хуже градиентного бустинга, но при этом он гораздо более прост в реализации.

2 Бустинг (Boosting)

Бустинг (англ. boosting — улучшение) — это процедура последовательного построения композиции алгоритмов машинного обучения, когда каждый следующий алгоритм стремится компенсировать недостатки композиции всех предыдущих алгоритмов. Бустинг представляет собой жадный алгоритм построения композиции алгоритмов. Изначально понятие бустинга возникло в работах по вероятно почти корректному обучению в связи с вопросом: возможно ли, имея множество плохих (незначительно отличающихся от случайных) алгоритмов обучения, получить хороший.

В течение последних 10 лет бустинг остаётся одним из наиболее популярных методов машинного обучения, наряду с нейронными сетями и машинами опорных векторов. Основные причины — простота, универсальность, гибкость (возможность построения различных модификаций), и, главное, высокая обобщающая способность.

Бустинг над решающими деревьями считается одним из наиболее эффективных методов с точки зрения качества классификации. Во многих экспериментах наблюдалось практически неограниченное уменьшение частоты ошибок на независимой тестовой выборке по мере наращивания композиции. Более того, качество на тестовой выборке часто продолжало улучшаться даже после достижения безошибочного распознавания всей обучающей выборки. Это перевернуло существовавшие долгое время представления о том, что для повышения обобщающей способности необходимо ограничивать сложность алгоритмов. На примере бустинга стало понятно, что хорошим качеством могут обладать сколь угодно сложные композиции, если их правильно настраивать.

2 Искусственные нейронные сети

Искусственные нейронные сети (ИНС) или нейросети - это вычислительные системы, вдохновленные биологическими нейронными сетями, которые лежат в основе мозга животных. Такие системы «учатся» выполнять задачи, рассматривая примеры, как правило, без программирования с помощью правил для конкретных задач. Например, при распознавании

изображений они могут научиться идентифицировать изображения, содержащие кошек, анализируя примеры изображений, которые были вручную помечены как «кошка» или «нет кошки», и используя результаты для идентификации кошек на других изображениях. Они делают это без какого-либо предварительного знания о кошках, например, что у них есть мех, хвосты, усы и кошачьи лица. Вместо этого они автоматически генерируют идентифицирующие характеристики из примеров, которые они обрабатывают.

ИНС основаны на наборе связанных единиц или узлов, называемых искусственными нейронами, которые слабо моделируют нейроны в биологическом мозге. Каждое соединение, подобно синапсам в биологическом мозге, может передавать сигнал другим нейронам. Искусственный нейрон, который получает сигнал, затем обрабатывает его и может сигнализировать нейронам, связанным с ним.

В реализациях ИНС «сигнал» в соединении является действительным числом, и выход каждого нейрона вычисляется по некоторой нелинейной функции суммы его входов. Связи называются ребрами. Нейроны и ребра, как правило, имеют вес, который изменяется в процессе обучения. Вес увеличивает или уменьшает силу сигнала при соединении. Нейроны могут иметь такой порог, что сигнал отправляется только в том случае, если совокупный сигнал пересекает этот порог. Как правило, нейроны объединены в слои. Разные слои могут выполнять разные преобразования на своих входах. Сигналы проходят от первого слоя (входного слоя) до последнего слоя (выходного слоя), после прохождения промежуточных (скрытых) слоев.

Первоначальная цель подхода ИНС состояла в том, чтобы решать проблемы так же, как это делает человеческий мозг. Но со временем внимание переключилось на выполнение конкретных задач, что привело к отклонениям от биологии. ИНС использовались для решения различных задач, включая компьютерное зрение, распознавание речи, машинный перевод, фильтрацию в

социальных сетях, игры в настольные и видеоигры, медицинскую диагностику и даже в тех видах деятельности, которые традиционно считались зарезервированными для людей, например рисование.

Нейронные сети не программируются в привычном смысле этого слова, они *обучаются*. Возможность обучения — одно из главных преимуществ нейронных сетей перед традиционными алгоритмами. Технически обучение заключается в нахождении коэффициентов связей между нейронами. В процессе обучения нейронная сеть способна выявлять сложные зависимости между входными данными и выходными, а также выполнять обобщение. Это значит, что в случае успешного обучения сеть сможет вернуть верный результат на основании данных, которые отсутствовали в обучающей выборке, а также неполных и/или «зашумленных», частично искажённых данных.

1 Компоненты нейронных сетей

Нейроны. ИНС состоят из искусственных нейронов, которые сохраняют биологическую концепцию нейронов, нейроны получают входные данные, объединяют входные данные с их внутренним состоянием (веса) и *порогом*, используя функцию *активации*, и производят выходные данные, используя функцию *вывода*.

Исходные данные - это внешние данные, такие как изображения, сигналы и документы. Важной характеристикой функции активации является то, что она обеспечивает плавный, дифференцируемый переход при изменении входных значений, то есть небольшое изменение входных данных приводит к небольшому изменению выходных данных.

Соединения и веса. Сеть состоит из соединений, каждое из которых обеспечивает выход одного нейрона в качестве входа для другого нейрона. Каждому соединению присваивается вес, который представляет его относительную важность. Каждый нейрон может иметь несколько входных и выходных соединений.

Архитектура (структура) ИНС. Нейроны обычно организованы в несколько слоев, особенно при глубоком обучении. Нейроны одного слоя соединяются только с нейронами непосредственно предшествующего и непосредственно следующего слоев. Слой, который получает внешние данные, является входным слоем. Слой, который дает конечный результат, является выходным слоем, между ними ноль или более скрытых слоев. Обычно используются ИНС с одним и более скрытых слоев. Между двумя уровнями возможны несколько схем подключения. Они могут быть *полностью связаны* с каждым нейроном в одном слое, соединяющимся с каждым нейроном в следующем слое. В качестве альтернативы, сети, которые позволяют соединения между нейронами в том же или предыдущих уровнях, известны как *рекуррентные сети*.

Гиперпараметр - это постоянный параметр, значение которого устанавливается до начала процесса обучения. Значения параметров выводятся с помощью обучения. Примеры гиперпараметров:

- скорость обучения
- количество скрытых слоев
- количество нейронов в слоях и т. д.

Значения некоторых гиперпараметров могут зависеть от значений других гиперпараметров. Например, размер некоторых слоев может зависеть от общего количества слоев.

Обучение - это адаптация сети, чтобы лучше справляться с задачей, рассматривая примеры наблюдений. Обучение включает в себя настройку весов (и необязательных порогов) сети для повышения точности результата. Это делается путем минимизации наблюдаемых ошибок. Обучение завершается, когда изучение дополнительных наблюдений не приводит к снижению частоты ошибок. Даже после обучения частота ошибок обычно не достигает 0. Если после обучения частота ошибок слишком высока, сеть обычно необходимо перепроектировать. Практически это делается путем определения функции стоимости, которая периодически оценивается в процессе обучения. Пока его

производительность продолжает снижаться, обучение продолжается. Обучение пытается уменьшить общее количество различий между наблюдениями. Большинство моделей обучения можно рассматривать как прямое применение теории оптимизации и статистической оценки.

Скорость обучения определяет размер корректирующих шагов, которые модель предпринимает для корректировки ошибок в каждом наблюдении. Высокая скорость обучения сокращает время обучения, но с более низкой конечной точностью, в то время как более низкая скорость обучения занимает больше времени, но с потенциалом для большей точности. Чтобы избежать колебаний внутри сети, таких как переменные веса соединений, и улучшить скорость сходимости, уточнения используют адаптивную скорость обучения, которая увеличивается или уменьшается соответственно.

3 Машинное обучение в электроэнергетике

С переходом к рыночным отношениям ЭЭС вынуждена работать на пределе запасов по надежности. При таких условиях любое возмущение, особенно сверхнормативное, может привести к снижению надежности системы вплоть до ее развала (например лавинообразное падение напряжения). Вследствие этого системные операторы должны четко чувствовать границу устойчивости во всех режимах ЭЭС, что очень сложно без анализа связанного с большим объемом вычислений. Проблема усугубляется еще и тем, что граница постоянно изменяется, по причине постоянных изменений в топологии сети и составе генерации и нагрузки, поэтому необходимы быстродействующие методы мониторинга режимной устойчивости в реальном времени, которые могут анализировать уровень устойчивости, отслеживать границу, «чувствовать» наиболее уязвимые области вдоль неё. Начиная с начала 90-х годов двадцатого века, были разработаны различные подходы и технологии для автоматизации этого процесса. К ним можно отнести приближенные методы на основе искусственного интеллекта, такие как алгоритмы машинного обучения [13, 14], мультиагентные системы [15].

В электроэнергетике наибольшее применение получили алгоритмы решающих деревьев и глубокое обучение (многослойные нейросети). Выбор вышеупомянутых алгоритмов объясняется их большой обобщающей способностью и быстрому распознаванию образов, помимо прочего данные алгоритмы обучения обладают быстрой скоростью обучения и идентификации границ неустойчивости, что очень важно при оценке режимных параметров в режиме реального времени. Основным принципом используемых в электроэнергетике алгоритмов машинного обучения заключается в обучении модели с достаточной точностью автоматически оценивать режим энергосистемы по критерию надежный/ненадежный на базе значимых классификационных признаков состояния ЭЭС. Множество таких признаков получают на основе случайно сгенерированной выборки данных, содержащей набор реально возможных состояний ЭЭС. Конечной целью является получение универсального классификатора состояний ЭЭС, способного на основе определенных режимных параметров отслеживать опасные предаварийные режимы и предсказывать аварийные ситуации в реальном времени.

Важной характеристикой экспертной системы или алгоритма машинного обучения при практическом применении является способ обновления. Можно выделить три основных способа обновления:

1. *онлайн-методы* — обновление исходного алгоритма/системы в реальном времени на реальных данных;
2. *методы периодического обновления* — каждый раз выполняется новое построение модели на накопленных данных;
3. *офлайн-методы* — построение модели обновляется единожды на большом массиве накопленных данных.

Использование машинного обучения и искусственного интеллекта в электроэнергетике, в том числе в вычислении критериев надежности режимов и устойчивости ЭЭС, активно изучается и трудно отрицать высокий потенциал внедрения искусственного интеллекта в системы контроля режима и автоматику ЭЭС [5]. В данной работе была исследована возможность создания метода по

оценке критерия статической устойчивости по мощности (K_p), который сможет дополнить существующие и разрабатываемые методы оценки устойчивости ЭЭС по данным СВИ и позволит увеличить надежность работы ЭЭС.

3 МОДЕЛИРОВАНИЕ ЭЭС ДЛЯ ИССЛЕДОВАНИЯ

Так как автором работы были выбраны алгоритмы машинного обучения «с учителем», то для проверки возможности применения алгоритмов на реальных данных требуется в первую очередь создать тренировочный и тестовый наборы данных. Так как нет открытого доступа к данным получаемым с СВИ, то очевидным способом для создания исследуемого набора данных является его моделирование.

Для моделирования ЭЭС и исследования статической устойчивости был выбран программный комплекс MUSTANG-95. В качестве схемы для моделирования была выбрана простейшая схема ЭЭС (рис 3.1), с одним генератором и ШБМ, и двумя ЛЭП между ними. После сбора системы и выставления параметров элементов системы, были подобраны сопротивления элементов системы (трансформатор, ЛЭП) таким образом, чтобы зафиксировать предел передаваемой мощности, меньший чем предельное значение генератора.

Моделирование было проведено для двух генераторов ТГ-25 и ТГ-80, для каждого генератора было смоделировано больше 50 переходных процессов и зафиксированы значения векторных значений (U , P , δ) на промежутке времени в 2 секунды.




Рисунок 3.1 — Простейшая схема ЭЭС.

1 ПК Мустанг и моделирование простейшей схемы ЭЭС

ПК Мустанг предназначен для оперативного выполнения на ЭВМ расчетов установившихся и переходных электромеханических режимов энергосистем. Вывод всех результатов расчета осуществляется в табличном виде на экран, в файл либо принтер. В комплекс Мустанг-95 включены также программные средства для вывода результатов расчета динамической устойчивости в виде графиков на экран, в файл либо принтер.

К достоинствам ПК Мустанг можно отнести следующие пункты [16]:

- Простота в использовании.
- Распространяется бесплатно.
- Возможность задания характеристик любой автоматики.

К недостаткам ПК Мустанг можно отнести неудобное графическое отображении данных и отсутствии готовых наборов автоматик. Для визуализации схемы была использована программа Visio, а для отображения графиков и визуализации данных библиотек matplotlib языка Python. Надобность в использовании каких-либо сложных наборов автоматики отсутствовала, поэтому второй недостаток выбранного ПК не повлиял на его выбор.

1 Выбор параметров схемы и расчет режима

Как уже упоминалось ранее в этой главе, первым шагом для решения поставленной задачи является моделирование системы. Для моделирования была выбрана простейшая схема ЭЭС (рис 3.1) с двумя ступенями напряжения 6,3 кВ/110 кВ. На рис. 3.2 фотографии программы с указанными параметрами элементов схемы.

(Скриншот)

Рисунок 3.2 — Фотография программы с заполненными параметрами.

Так как цель данной работы напрямую связана с определением статической устойчивости, следующим шагом после моделирования схемы было определение предела передаваемой мощности и его корректировка, путем

изменения сопротивления элементов схемы, до значения соразмерного с величиной номинальной мощности генератора. На рис. 3.3 изображены параметры схемы и расчет режима в приложении Мустанг для режима, предел передаваемой мощности которого соответствует значению 23,7 МВт, при увеличении мощности генерации режим не рассчитывается, а следовательно не балансируется и является неустойчивым. Для изменения предела передаваемой мощности были специальным образом подобраны сопротивления трансформатора и ЛЭП, они были искусственно завышены, что привело к уменьшению предела передаваемой мощности.

(Рисунок)

Рисунок 3.3 — Расчет режима смоделированной системы с искусственно заниженным значением передаваемой мощности.

2 Моделирование возмущающего воздействия и регистрирование векторных параметров сети

В качестве возмущающего воздействия было принято самое простое и наиболее частое возмущение: отключение одной из двух параллельно работающих ЛЭП.

Возвращаясь ко взятому ранее примеру схемы, со значением предела передаваемой мощности равным 23,7 МВт, следует отметить, что после возмущения (отключения одной ЛЭП) общее сопротивление схемы повысилось, в следствии чего предел передаваемой мощности уменьшился и стал равным 21,8 МВт (рис3.4).

(а Схема с одноцепной линией) (б Фото из Мустанга)

Рисунок 3.4 — Расчет режима для послеаварийной схемы: а — электрическая схема, б — фотография расчета из ПК Мустанг.

Следующим этапом после выбора возмущающего воздействия и нахождения пределов передаваемой мощности для обоих вариантов схем стало моделирование поведения системы во времени (на протяжении 2 с), для чего использовался режим Автоматики в ПК Мустанг.

Во время моделирования процесса отключения ЛЭП во времени регистрировались следующие параметры в соответствии со схемой (рис. 3.1):

- Время (t , с),
- Напряжение на шинах генератора (U_g , кВ),
- Напряжение на высокой стороне трансформатора (U , кВ),
- Переток мощности в одной из двух параллельных линии (P_{ij} , МВт),
- Мощность выдаваемая генератором (P_g , МВт),
- Мощность турбины (P_t , МВт) — постоянная величинами,
- Относительный угол напряжения (δ , град).

Из выше перечисленных величин для дальнейшего исследования будут использоваться только четыре: время, напряжение на высокой стороне трансформатора (как более информативное), мощность генератора и относительный угол δ .

Такой выбор объясняется тем, что оба сигнала напряжения ведут себя одинаково и отличаются только степенями напряжения, поток мощности не отличается ничем кроме значения потерь в продольных элементах, однако при отключении линии он резко изменяется (весь переток идет по одной линии вместо двух), что может плохо повлиять на исследуемые модели и измерение на шинах генератора проще на практике.

В результате подбора всех параметров, выбора измеряемых значений и возмущающего воздействия в ПК Мустанг — была задана автоматика, в результате действия которой система переходила из нормального режима в послеаварийный и измерялись режимные параметры (сигналы U , P , δ) на протяжении 2 с.

Результаты измерений экспортировались в виде таблиц в текстовые файлы (пр.: табл. 3.1.), для каждой отдельной схемы проводилось 40 измерений. Из этих 40 измерений в половине случаев система имела коэффициент запаса статической устойчивости по активной мощности меньше 8%, а вторая половина измерений проводилась для системы имеющей запас статической устойчивости по активной мощности больше 8%. Все пределы были рассчитаны относительно предельной передаваемой мощности в послеаварийном режиме (с одной работающей ЛЭП).

Таблица 3.1 — Пример результата измерений, полученного в ходе расчета режима в динамике. Для данного примера $P_{п} = 23.7 \text{ МВт}$, $92\% * P_{п} = 20 \text{ МВт}$.

t	U _g	U _s	P _{ij}	P _g	P _{gt}	delta
0.010	6.300	110.000	9.974	21.700	21.700	69.95
0.020	6.300	110.000	9.974	21.700	21.700	69.95
0.030	6.300	110.000	9.974	21.700	21.700	69.95
0.040	6.300	110.000	9.974	21.700	21.700	69.95
...
0.270	6.388	109.999	17.592	18.903	21.700	70.11
0.280	6.388	109.999	17.597	18.910	21.700	70.16
0.290	6.387	109.999	17.603	18.917	21.700	70.22
0.300	6.387	109.999	17.610	18.926	21.700	70.28
0.310	6.386	109.998	17.617	18.935	21.700	70.35
0.320	6.385	109.998	17.624	18.945	21.700	70.42
0.330	6.384	109.998	17.633	18.956	21.700	70.50
0.340	6.383	109.998	17.642	18.967	21.700	70.58
0.350	6.382	109.998	17.651	18.980	21.700	70.68
0.360	6.381	109.998	17.661	18.993	21.700	70.77
0.370	6.379	109.998	17.672	19.007	21.700	70.88
0.380	6.378	109.998	17.683	19.021	21.700	70.99
...
1.940	5.519	109.914	13.272	16.584	21.700	134.18
1.950	5.509	109.913	13.096	16.426	21.700	134.95
1.960	5.500	109.912	12.914	16.262	21.700	135.74
1.970	5.490	109.912	12.727	16.094	21.700	136.54
1.980	5.481	109.911	12.534	15.920	21.700	137.35
1.990	5.471	109.910	12.336	15.740	21.700	138.17
2.000	5.461	109.909	12.132	15.555	21.700	139.01


На этом заканчивается первый этап данной работы, который заключался в генерации данных для дальнейшего обучения моделей машинного обучения.

Для моделирования послеаварийных режимов было использовано два генератора (ТГ-25 и ТГ-80) параметры которых приведены в Приложении А, вместе с обоснованием их выбора. Для генератора ТГ-25 было смоделировано две различных схемы с различными значениями предела передаваемой мощности, для каждой схемы было проведено более 50 измерений режимных параметров во времени (различная мощность генерации). Для ТГ-80 было спроектировано три схемы с различными пределами передаваемой мощности и для каждой из которых были проведены измерения режимных параметров аналогично схемам с ТГ-25.

В результате моделирования различных режимов для разных параметров схемы было получено 3 группы режимов:

1. Режимы с коэффициентом запаса по активной мощности в пределах $[0, 8]\%$ (пр.: рис 3.5а);
2. Режимы с коэффициентом запаса по активной мощности в пределах $(0, 20]\%$ (пр.: рис 3.5б);
3. Режимы с коэффициентом запаса по активной мощности в пределах $(20, 35]\%$ (пр.: рис 3.5в);

Для проверки гипотезы было решено использовать все схемы с генератором ТГ-25 в качестве обучающих данных, а проверять обученные алгоритмы на схемах с генератором ТГ-80. В результате моделирования была построена модель простейшая модель ЭЭС, на основе которой было смоделировано около 300 различных режимов для их дальнейшего исследования, каждый режим соответствует одной из трех категорий по коэффициенту запаса статической устойчивости по активной мощности.






Рисунок 3.5. Примеры смоделированных режимов и сигналы векторных измерений в момент переходного процесса для различных значений K_p : а — переходные процессы для генератора ТГ-25 с $K_p \leq 8\%$; б — переходные процессы для генератора ТГ-80 с K_p в пределах $(8\%, 20\%]$.

4 ОБРАБОТКА РЕЗУЛЬТАТОВ МОДЕЛИРОВАНИЯ И ПОСТРОЕНИЕ МОДЕЛЕЙ

Следующим этапом после генерации данных является обработка и исследование полученных данных, процесс обработки данных можно разделить на следующие этапы:

1. Приведение всех данных к одному формату
2. Обработка и преобразование данных
3. Выбор модели:
 1. Модели для работы с табличными данными
 2. Модели для обработки «сырого» сигнала (ИНС)
4. Подбор параметров модели (гиперпараметров)
5. Оценка качества предсказаний для всех моделей

Как было упомянуто выше для обучения было решено использовать данные полученные для генератора ТГ-25, а тестировать на режимах полученных для генератора ТГ-80. Два различных генератора было выбрано для того, чтобы обеспечить чистоту и непредвзятость эксперимента.

2 Обработка данных

1 Подготовка данных

В результате моделирования были получены значения сигналов на протяжении двух секунд для различных режимов в текстовом формате. Поэтому первым делом эти текстовые данные были приведены к табличному формату *.csv (comma separated values) и переведены в универсальную кодировку (UTF-8).

Àäâÿ	U 601	U 1002	Plj 1001 1002 1	ðà 601	ðò à 601	ôäie ôïò 601	t,Ug,Us,Plj,Pg,Pgt,delta
							0.010,6.300,110.000,9.974,21.700,21.700,69.95
							0.020,6.300,110.000,9.974,21.700,21.700,69.95
							0.030,6.300,110.000,9.974,21.700,21.700,69.95
							0.040,6.300,110.000,9.974,21.700,21.700,69.95
							0.050,6.300,110.000,9.974,21.700,21.700,69.95
							0.060,6.300,110.000,9.974,21.700,21.700,69.95
							0.070,6.300,110.000,9.974,21.700,21.700,69.95
							0.080,6.300,110.000,9.974,21.700,21.700,69.95
							0.090,6.300,110.000,9.974,21.700,21.700,69.95
							0.100,6.300,110.000,9.974,21.700,21.700,69.95
							0.110,6.300,110.000,9.974,21.700,21.700,69.95
							0.120,6.300,110.000,9.974,21.700,21.700,69.95
							0.130,6.300,110.000,9.974,21.700,21.700,69.95
							0.140,6.300,110.000,9.974,21.700,21.700,69.95
							0.150,6.300,110.000,9.974,21.700,21.700,69.95
							0.160,6.300,110.000,9.974,21.700,21.700,69.95
							0.170,6.300,110.000,9.974,21.700,21.700,69.95
							0.180,6.300,110.000,9.974,21.700,21.700,69.95
							0.190,6.300,110.000,9.974,21.700,21.700,69.95
							0.200,6.300,110.000,9.974,21.700,21.700,69.95
							0.210,6.300,110.000,9.974,21.700,21.700,69.95
							0.220,6.300,110.000,9.974,21.700,21.700,69.95
							0.230,6.300,110.000,9.974,21.700,21.700,69.95
							0.240,6.300,110.000,9.974,21.700,21.700,69.95
							0.250,6.300,110.000,9.974,21.700,21.700,69.95
							0.260,6.300,110.000,9.974,21.700,21.700,69.95
							0.270,6.300,110.000,9.974,21.700,21.700,69.95
							0.280,6.300,110.000,9.974,21.700,21.700,69.95
							0.290,6.300,110.000,9.974,21.700,21.700,69.95
							0.300,6.300,110.000,9.974,21.700,21.700,69.95
							0.310,6.300,110.000,9.974,21.700,21.700,69.95
							0.320,6.300,110.000,9.974,21.700,21.700,69.95

Рисунок 4.1 — Пример данных полученных в ходе моделирования, до очистки (а) и после преобразования (б).

Следующим этап, после преобразования формата файлов, - нормализация всех сигналов. Нормализация является необходимой для данных используемых в этой работе по причинам:

1. Сигналы используемые для обучения/предсказания характеризуют различные величины и следовательно имеют различные предельные значения,
2. Различные исследуемые режимы могут отличаться по значения сигнала, но нас интересует его форма, а не амплитудные значения.
3. Нормализация также необходима для масштабируемости модели (использование на других генераторах, других настройках автоматики).

Самыми распространенными методами нормализации данных являются:

- *Z-нормализация (стандартизация)* — исходная величина преобразуется в число стандартных отклонений, на которые значение необработанной оценки (то есть наблюдаемое значение или точка данных) выше или ниже среднего значения того, что наблюдается или измеряется. Необработанные оценки выше среднего имеют положительные стандартные оценки, в то время как показатели ниже среднего имеют отрицательные стандартные оценки. Z-нормализация вычисляется по следующей формуле:

$$S(t) = (S(t) - S_{mean}) / \sigma(S), \quad (3.1)$$

где $S(t)$ - значение сигнала в момент времени t , S_{mean} — среднее значение сигнала на промежутке времени в 2 секунды, $\sigma(S)$ — среднеквадратичное отклонение сигнала на промежутке времени в 2 секунды, t — время замера сигнала относительно первого момента измерения с дискретностью в 10 миллисекунд.

- Масштабирование - это метод, используемый для нормализации диапазона независимых переменных или характеристик данных. При обработке данных это также называется нормализацией данных и обычно выполняется на этапе предварительной обработки данных. Обычно после масштабирования все значения нормализованной величины лежат на отрезке $[0, 1]$. Для масштабирования величины используется следующая формула:

$$S(t) = (S(t) - S_{\min}) / (S_{\max} - S_{\min}), (3.2)$$

где $S(t)$ - значение сигнала в момент времени t , S_{\min} — минимальное значение сигнала на промежутке времени в 2 секунды, S_{\max} — максимальное значение сигнала на промежутке времени в 2 секунды, t — время замера сигнала относительно первого момента измерения с дискретностью в 10 миллисекунд.

- Приведение к относительным единицам, используемое при расчетах переходных режимов. Данный метод тоже является масштабированием, но в данном случае масштабирование происходит за счет заранее выбранных значений напряжения (U) и мощности (P), в данной работе в качестве значений были взяты исходные параметры режима номинальное напряжение генератора ($U_{\text{ном}}$) и мощность турбины ($P_{\text{гт}}$).

Относительный угол (δ) был масштабирован делением на 180 градусов, так как угол не может иметь значение больше 360 градусов, поэтому относительный угол между векторами напряжений был приведен к значениям $[0, 2]$.

На табличных данных лучшие результаты показали данные, прошедшие через масштабирование, разница в точности между стандартизацией и масштабированием составила 5%. Для сырых данных с последующим использованием нейросетей лучшие результаты показало «классическое» масштабирование с дальнейшим приведением среднего значения к нулю (рис 4.2б). Результаты преобразований приведены на рисунке 4.2, на них видно что после преобразования все сигналы, независимо от измеряемой величины лежат в пределах $[0, 1]$.




Рисунок 4.2 — Пример сигналов, после нормализации (масштабирования) для трех различных физических величин, а — масштабирование для табличных данных, б — масштабирование для нейросети.

2 Преобразование данных и извлечение признаков

Большинство моделей машинного обучения требуют для работы табличных данных, то есть данных в которых каждому обучающему примеру соответствует какое-то количество признаков и правильный ответ. Данные же полученные после моделирования представляют из себя три сигнала во времени, которые по определению не соответствуют табличным данным, поэтому следующим этапом является преобразование каждого сигнала в ряд скалярных значений которые смогут отражать значение характер и форму сигнала.

Существует множество преобразований сигнала результатом которых является скалярная величина, это могут быть как простейшие характеристики сигнала (среднее значение, амплитуда и т. д.), так и более сложные (быстрое преобразование Фурье, производная и т. д.). По причине большого разнообразия параметров характеризующих сигнал было решено воспользоваться специальным программным модулем для языка Python — *tsfresh* [17].

tsfresh - это пакет для языка программирования Python. Он автоматически рассчитывает большое количество характеристик временных рядов, так

называемых функций. Кроме того, пакет содержит методы для оценки объясняющей силы и важности таких характеристик для задач регрессии или классификации.

Для каждого из трех сигналов (U , P , δ) в каждом режиме было произведено преобразование с использованием модуля `tsfresh` и выделено около 600 признаков, в таблице 4.1 приведены примеры самых релевантных признаков и их описание.

Таблица 4.1 — Некоторые признаки, полученные из сигналов и их описание.

Метка признака в коде	Описание признака	Формула для вычисления
cwt_coefficients	Непрерывное вейвлет-преобразование - вычисляет внутренние произведения непрерывного сигнала с помощью набора непрерывных вейвлетов	$WT_{u,a} = \left\langle s, \psi_{u,a} \right\rangle = \int_{-\infty}^{\infty} s(t) \psi_{u,a}^*(t) dt$
fft_coefficient	Быстрое преобразование Фурье = Дискретному преобразованию Фурье	$X_k = \sum_{n=0}^{N-1} x_n e^{-\frac{2\pi i}{N} kn}$
count	Подсчет значений	$ \Omega $
quantile	Квантиль - значение, которую сигнал не превышает с фиксированной вероятностью	$\mathbb{P}(X \leq x_\alpha) \geq \alpha$
energy_ratio	Вычисляет сумму квадратов фрагмента i из N фрагментов, выраженную в виде отношения с суммой квадратов по всему ряду.	

Так как в сумме получилось больше 1500 признаков, что слишком много для предсказательных моделей, было решено отобрать по 80 самых значимых признаков для каждого измеренного сигнала. Релевантность признака оценивалась с помощью мета-классификатора (ансамбля решающих деревьев) который строит множество небольших моделей (деревьев решений) и оценивает вклад каждого признака в точность предсказания. Таким образом были

получены 100 признаков для каждого сигнала, которые коррелируют больше всего с целевой переменной. На рисунках 4.2(а-в) приведены диаграммы отображающие по 10 самых значимых признаков для каждого сигнала.

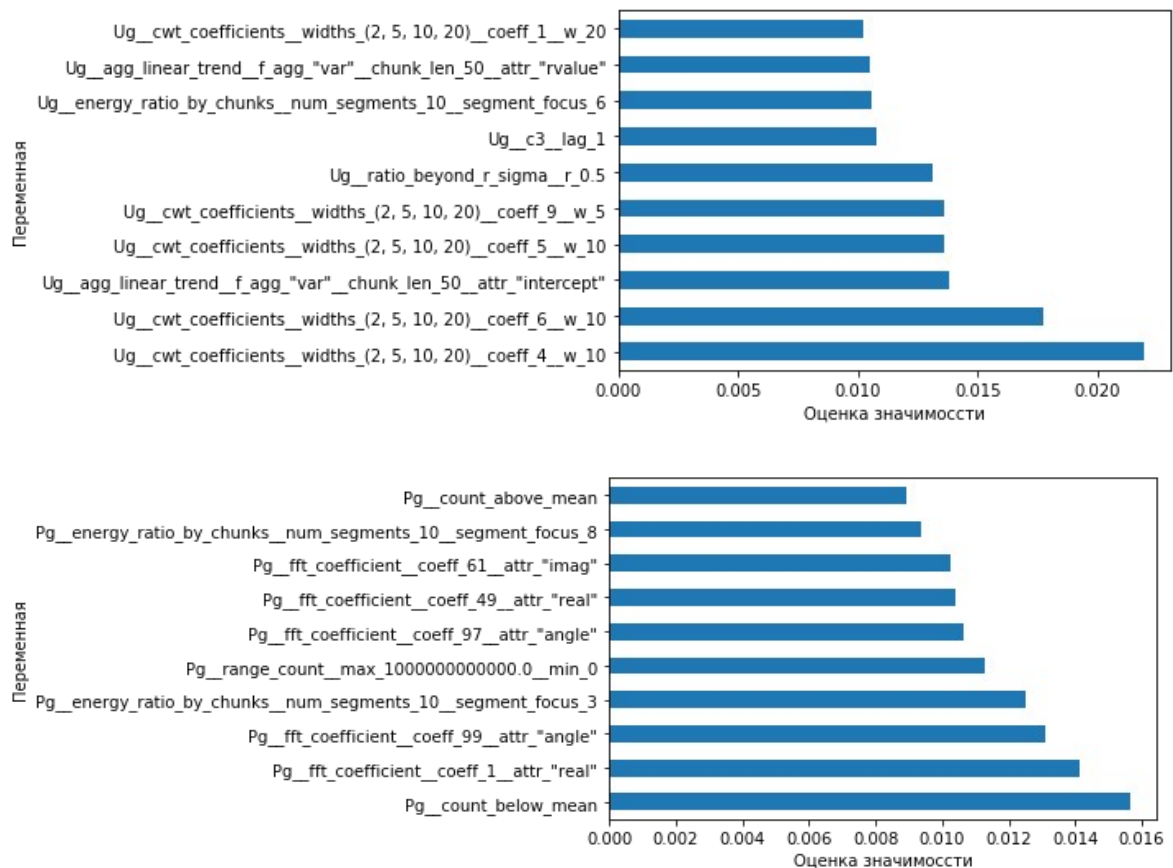


Рисунок 4.2 — Диаграммы отображающие самые релевантные признаки и их относительную ценность для сигналов напряжения и передаваемой мощности.

3 Выбор метрик оценки и построение моделей

Следующим шагом после формирования данных является непосредственное тестирование различных моделей машинного обучения, для определения наиболее эффективной модели и дальнейшего поиска оптимальных параметров для выбранной модели. Для сравнения моделей между собой используются две метрики (см. раздел 4.4.1) точность классификации и средняя точность классификации модели.

Как уже упоминалось в главе 3, данные были разделены на две группы по генератором, на основе которых моделировалась простейшая схема ЭЭС:

- ТГ-25 — обучающая выборка;
- ТГ-80 — проверочная (валидационная) выборка.

Обучающая выборка - это набор примеров, используемых для обучения модели. Модель (например, нейронная сеть или наивный байесовский классификатор) обучается на наборе обучающих данных с использованием контролируемого метода обучения, например, с использованием методов оптимизации, таких как градиентный спуск или стохастический градиентный спуск. На практике обучающий набор данных часто состоит из пар входного вектора (или скаляра) и соответствующего выходного вектора (или скаляра), где ключ ответа обычно обозначается как цель (или метка). Модель запускается с набором обучающих данных и выдает результат, который затем сравнивается с истинным значением, для каждого входного вектора в наборе обучающих данных. Последовательно, подобранная модель используется для прогнозирования ответов для наблюдений во втором наборе данных, называемом набором проверочных данных.

Набор *проверочных данных* обеспечивает беспристрастную оценку соответствия модели учебному набору данных при настройке гиперпараметров модели. Наборы данных для проверки могут быть использованы для регуляризации путем ранней остановки (остановки обучения, когда увеличивается ошибка в наборе данных для проверки, так как это является признаком переобучения на обучающей выборке). Эта простая процедура на практике усложняется тем фактом, что ошибка набора данных проверки может колебаться во время обучения, создавая несколько локальных минимумов.

1 Выбор метрик

Метрики оценки используются для измерения качества статистической или модели машинного обучения. Метрики оценки моделей/алгоритмов машинного обучения является неотъемлемой частью любого проекта или исследования, так как позволяет оценить эффективность работы алгоритма и сравнить различные алгоритмы. Существует много различных типов оценочных

метрик, доступных для тестирования модели. К ним относятся точность классификации, логарифмическая функция потерь, матрица несоответствий и другие.

Как уже упоминалось в главе 3 и во Введении в данной работе решается задача классификации, а именно классификация режима ЭЭС по сигналам векторных измерений. То есть фактически задача регрессии, определение коэффициента запаса по активной мощности, была переведена в задачу классификации, путем распределения всех режимов по трем классам:

1. $0\% \leq K_{\text{п}} \leq 8\%$;
2. $8\% < K_{\text{п}} \leq 20\%$;
3. $K_{\text{п}} > 20\%$;

Основным критерием оценки задачи классификации является точность предсказаний, однако данная задача является многоклассовой, в следствие чего, точность предсказаний не может использоваться в качестве достаточного критерия оценки моделей, так как не отражает точность классификации среди отдельных классов. По причине малой информативности критерия точности, в данной работе решено использовать несколько критериев и в качестве показательного и наглядного критерия оценки моделей решено использовать матрицу несоответствий.

Точность классификации (Accuracy) - это отношение количества правильных предсказаний ко всем предсказываемым примерам.

Функция логарифмических потерь (LogLoss) — обычно используется в качестве функции стоимости, так как является непрерывной и дифференцируемой, однако является сложной для интерпретации.

Матрица несоответствий (Confusion matrix) — представляет из себя матрицу, которая описывает точность предсказания модели для каждого класса.

Средняя точность классификации (macro F1 score) — вычисляется как средняя точность для каждого класса, в отличии от точности классификации не зависит от количества экземпляров в каждом классе.

Помимо вышеупомянутых метрик для оценки моделей существует еще множество других более специфичных метрик, которые однако не будут использоваться в данной работе, так как упомянутых выше метрик будет достаточно для оценки возможности предсказания запаса устойчивости и сравнения различных моделей между собой.

2 Обучение моделей на табличных данных

Обучение модели представляет из себя процесс подбора оптимальных параметров модели таким образом, чтобы минимизировать ошибку предсказания на обучающей выборке. В контролируемом обучении алгоритм машинного обучения строит модель, изучая множество примеров и пытаясь найти модель, минимизирующую потери.

Как уже было упомянуто выше в данной работе решается задача классификации, поэтому все рассматриваемые в данной главе модели являются классификаторами, а следовательно все они возвращают вероятность принадлежности к каждому из классов для каждого экземпляра.

Задача многоклассовой классификации в отличие от задачи бинарной классификации не может быть решена простой моделью, так большинство линейных и ансамблевых моделей машинного обучения лишь возвращают вероятность принадлежности экземпляра к одному классу, поэтому прежде чем приступать к выбору модели следует выбрать стратегию комбинирования моделей, наиболее подходящую к этой задаче. Самыми распространенными подходами к многоклассовой классификации, которые и будут рассмотрены в данной работе являются:

- «Один против всех» (One-VS-Rest) — создается ансамбль бинарных классификаторов, в котором каждый классификатор определяет принадлежность экземпляра к одному конкретному классу, то есть количество классификаторов соответствует количеству классов.
- «Каждый против Каждого» (One-VS-One) - классификаторы строятся для каждой пары классов для того, чтобы можно было однозначно разделить

любые два класса из множества A . Количество классификаторов в этом случае равно $n(n-1)/2$. После подачи на входы каждого из обученных классификаторов тестового образца получаем ответы, содержащие информацию о его принадлежности одному из двух классов, участвовавших в обучении. К полученному множеству ответов применяется схема мажоритарного голосования и класс, выбранный большинством классификаторов, принимается как итоговое решение.

Две различные стратегии OVA и OVO были проверены для большого количества классификаторов, помимо указанных в главе 2 ансамблевых методов были рассмотрены дополнительные алгоритмы машинного обучения, краткое описание которых будет дано ниже.

Наивный байесовский классификатор - это простой метод построения классификаторов, основанных на применении теоремы Байеса: моделей, которые присваивают метки классов экземплярам, представленным как векторы значений признаков, где метки классов принадлежат некоторому конечному набору. Не существует единого алгоритма для обучения таких классификаторов, но есть семейство алгоритмов, основанных на общем принципе: все наивные байесовские классификаторы предполагают, что значение определенного признака не зависит от значения любого другого признака, заданного переменной класса.

Метод опорных векторов - создает гиперплоскость или набор гиперплоскостей в пространстве высокой или бесконечной размерности, которые могут использоваться для классификации, регрессии или других задач, таких как обнаружение выбросов. Интуитивно понятно, что хорошее разделение достигается с помощью гиперплоскости, которая имеет наибольшее расстояние до ближайшей точки обучающих данных любого класса (так называемый функциональный запас), поскольку, как правило, чем больше запас, тем ниже ошибка обобщения классификатора.

AdaBoost (Адаптивный бустинг) - мета-алгоритм машинного обучения, сформулированный Йоавом Фрейндом и Робертом Шапире, который может

использоваться в сочетании со многими другими типами алгоритмов обучения для повышения производительности. Результаты других «слабых» алгоритмов обучения объединяются во взвешенную сумму, которая представляет окончательный результат классификатора. AdaBoost адаптивен в том смысле, что последующие слабые классификаторы настроены в пользу тех случаев, которые были ошибочно классифицированы предыдущими классификаторами. AdaBoost чувствителен к шумным данным и выбросам. В некоторых задачах он может быть менее восприимчив к проблеме переобучения, чем другие алгоритмы обучения.

Градиентный бустинг - мета-алгоритм машинного обучения для задач регрессии и классификации, которая создает модель прогнозирования в виде множества моделей слабого прогнозирования, обычно деревьев решений. Он строит модель поэтапно, как и другие методы в бустинге, и обобщает их, позволяя оптимизировать произвольную дифференцируемую функцию потерь.


Результаты оценки эффективности двух стратегий классификации («Один против всех» и «Каждый с каждым») приведены в таблице 4.1. Для всех проверок использовались одни и те же данные и каждая модель тестировалась по пять раз с усреднением результатов, чтобы нивелировать влияние случайной величины.

Таблица 4.1. Результаты сравнения двух различных стратегий классификации OVO («Каждый с каждым») и OVR («Один против всех»).

Стратегия классификации	OVO		OVR	
	Точность, %	Средняя точность по классам, %	Точность, %	Средняя точность по классам, %
AdaBoost	50,2	43,8	54,4	50,9
Наивный Байесовский классификатор	75,4	71,7	74,9	71,2
Метод опорных векторов	56,7	42,7	53,8	41
Случайный лес	63,1	55,6	63,7	56
Градиентный бустинг (CatBoost)	63,7	60,5	70,1	67,4

Как видно из диаграммы на рисунке 4.3, которая представляет из себя визуализацию средней точности из таблицы 4.1 в большинстве случаев лучший

результат показывает стратегия обучения OVR («Один против всех»), кроме метода опорных векторов, который однако показал плохие результаты в сравнение с прочими методами на обоих стратегиях. В случае с наивным Байесовским классификатором обе стратегии показывают схожие результаты, отличающиеся менее чем на один 1%, что не является значимым и может быть результатом шума в тестовой выборке. Методы основанные на деревьях решений (AdaBoost, Случайный лес и Градиентный бустинг) показали лучшие результаты с использованием стратегии «Один против всех», причем разница в значении достигает 6%. Исходя из вышесказанного для дальнейшего исследования моделей машинного обучения на табличных данных в данной работе была выбрана стратегия «Один против всех» и дальнейшие результаты в данной главе будут подразумевать использование данной стратегии.



Рису

нок 4.3. Диаграмма значения точности для разных алгоритмов МО в зависимости от стратегии многоклассовой классификации.

Прежде чем переходить к выбору лучшей модели хочется разобрать несколько отличающихся примеров из таблицы 4.1. Рассмотрим метод опорных векторов, из таблицы 4.1 видно что в отличии от других методов МО, у данного алгоритма наблюдается сильное различие между точностью по выборке и

средней точности по классам. Чтобы объяснить такое поведение метрик обратимся к матрице несоответствий (табл. 4.2) построенной на уже обученном алгоритме с использованием метода опорных векторов.

Таблица 4.2. Таблица несоответствий для метода опорных векторов, получившаяся в результате предсказания тестовой выборки.

		Предсказанное значение		
		$0\% < Kп \leq 8\%$	$8\% < Kп \leq 20\%$	$Kп > 20\%$
Истинное значение	$0\% < Kп \leq 8\%$	35	15	0
	$8\% < Kп \leq 20\%$	19	57	0
	$Kп > 20\%$	15	30	0

Матрица несоответствий имеет самое наглядное представление результатов предсказания модели, например таблицу 4.2 следует интерпретировать так: моделью было предсказано $35 + 16 + 19 = 69$ режимов как аварийных ($Kп \leq 8\%$), из которых только 35 являются истинно аварийными, 19 принадлежат режиму с $8\% < Kп \leq 20\%$ и 15 режимов имеют $Kп > 20\%$. То же самое верно и для оставшихся двух предсказаний модели, теперь возвращаясь к таблице 4.1 можно объяснить почему данный алгоритм имеет такую низкую среднюю точность, как видно из таблицы 4.2 метод опорных векторов не предсказал ни одного режима из класса режимов с $Kп > 20\%$, именно этим фактом и объясняется такое отличие между двумя метриками (точностью и средней точностью по классам). Ведь средняя точность по классам вычисляется следующим образом: сначала вычисляется точность для каждого класса и усредняется, а так как точность в классе $Kп > 20\%$ равна нулю, то и среднее получается очень малым значением. Подобные предсказания для данного метода объясняются самой сутью метода, в основе которого лежит построение гиперплоскости для разделения двух классов между собой с максимизацией зазора.

Возвращаясь к выбору моделей лучше всего себя показали методы градиентного бустинга и наивного Байесовского классификатора. Следующим этапом после выбора моделей является поиск оптимальных значений

гиперпараметров для данных алгоритмов и поиск самого оптимального их сочетания.

В отличие от градиентного бустинга, где перед запуском обучения задается большое количество гиперпараметров в наивном Байесовском классификаторе нет каких-либо гиперпараметров, так как такой классификатор строится исходя из предположения о том, что все признаки являются независимыми и для каждого признака вычисляется вероятность принадлежности экземпляра к определенному классу в зависимости от значения признака. Однако как упоминалось ранее в данной работе количество признаков сгенерированных для исходных данных составило больше 1500, но для тестирования и обучения моделей было решено оставить по 80 признаков на каждый, поэтому можно варьировать количество признаков и их тип для поиска оптимального количества переменных, которое даст самую большую точность. На рисунке 4.4 представлен график зависимости точности предсказаний и средней точности предсказаний по классам для наивного Байесовского классификатора, как видно из графика оптимальное количество признаков для данного классификатора — 90.




Рисунок 4.4. Точность классификации в зависимости от количества признаков для каждого сигнала.

Как видно из графика на рисунке 4.4 при самом оптимальном количестве признаков (90) точность классификации достигает значения 77%, чтобы подробнее разобраться в результатах данного классификатора обратимся к матрице несоответствий построенной по предсказаниям наилучшего Байесовского классификатора и записанной в таблице 4.3. Как видно из таблицы лучше всего классификатор справляется с предсказанием режима с $Kп < 8\%$, здесь его точность достигает 90%, режимы с $Kп$ лежащем в отрезке $(8\%, 20\%]$ алгоритм делает предсказания с 75% точностью, а хуже всего алгоритм определяет режимы с $Kп > 20\%$. Такое поведение точности предсказаний связано с тем, что граница между двумя последними типами режимов крайне условная (20% запаса устойчивости) и определена теоретически, а значит никак не связана с реальными физическими процессами.

Таблица 4.3. Матрица несоответствий для лучшей модели построенной на основе наивного Байесовского классификатора.

		Предсказанное значение		
		$0\% < Kп \leq 8\%$	$8\% < Kп \leq 20\%$	$Kп > 20\%$
Истинное значение	$0\% < Kп \leq 8\%$	45	5	0
	$8\% < Kп \leq 20\%$	5	57	14
	$Kп > 20\%$	0	31	14

Перейдем к исследованию градиентного бустинга, в данном алгоритме машинного обучения существует большое множество гиперпараметров которые можно варьировать для улучшения результата, основные из них и их описание приведены в таблице 4.4. Также по аналогии с наивным Байесовским классификатором было определено оптимальное количество параметров на каждый сигнал для различной глубины деревьев(см. `max_depth` в табл. 4.4).

Таблица 4.4. Основные гиперпараметры градиентного бустинга (CatBoost), настраиваемые для определения оптимальной модели.

Гиперпараметр	Описание
n_estimators	Количество деревьев, используемых в ансамбле
max_depth	Максимальная «глубина» каждого решающего дерева
learning_rate	Скорость обучения, определяет размер шага на каждой итерации
loss_function	<p>Функция потерь (стоимости), в данной работе используется «Multiclass»</p> $\frac{\sum_{i=1}^N w_i \log \left(\frac{e^{a_{ii}}}{\sum_{j=0}^{M-1} e^{a_{ij}}} \right)}{\sum_{i=1}^N w_i},$
random_state	Фиксация ГПСЧ для возможности повторения эксперимента
l2_leaf_reg	Коэффициент L2 регуляризации в функции стоимости

Рисунок 4.5. График зависимости точности предсказания от количества экземпляров.

Как видно на рисунке 4.5 наилучшую производительность показал градиентный бустинг при глубине деревьев равной 3 с использованием 80 признаков для каждого сигнала, при прочих стандартных настройках. Следующим этапом по оптимизации модели является подбор гиперпараметров (табл. 4.4). В данной работе будет приведена лишь часть проведенной работа, на практике было протестировано около 500 различных настроек данной модели, однако большинство из них не обладали выдающейся точностью, чтобы их стоило упоминать, примеры некоторых конфигураций приведены в таблице 4.6.

Таблица 4.5. Примеры некоторых протестированных конфигураций моделей и их производительность.

Параметры модели	Средняя точность	Точность по классам
n_estimators=300, max_depth=4, learning_rate=0.5, loss_function='MultiClass'	73,1	69,9
n_estimators=300, max_depth=4, learning_rate=0.55, loss_function='MultiClass'	73,7	70,5
n_estimators=500, max_depth=2, learning_rate=0.7	74,9	73,7
n_estimators=500, max_depth=3, Learning_rate=0.7,	78,9	78,9
n_estimators=300, max_depth=3, learning_rate=0.7, class_weights=[1.7,1,1], l2_leaf_reg=3	78,4	76,1

Для поиска оптимального классификатора (модели) варьировались следующие гиперпараметры:

1. Скорость обучения (learning rate) - варьировалась от 0,1 до 0,95 с различным шагом, график точности приведен на рисунке 4.6.

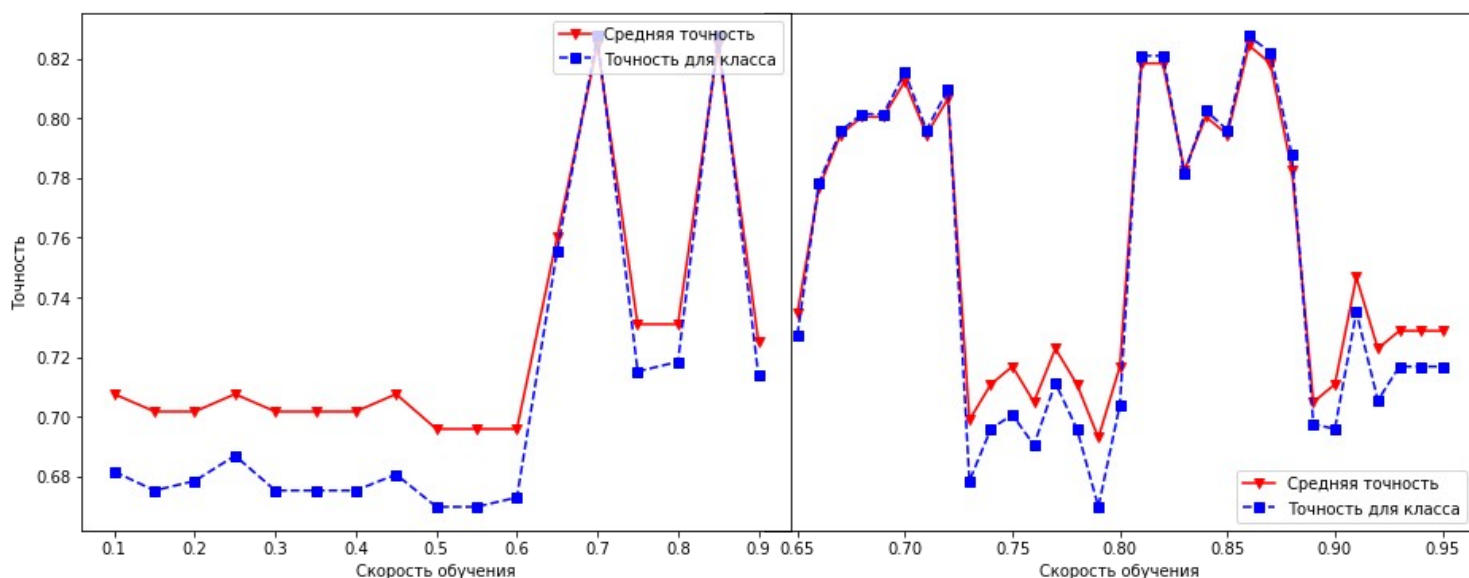


Рисунок 4.6. График зависимости точности от скорости обучения.

2. Коэффициент L2 регуляризации (l2_leaf_reg) — варьировался от 1.5 до 3, график приведен на рисунке 4.7.




Рисунок 4.7. График зависимости точности от коэффициента L2 регуляризации.

3. Количество деревьев (`n_estimators`) — варьировались от 200 до 900, график изменения точности в зависимости от количества деревьев.

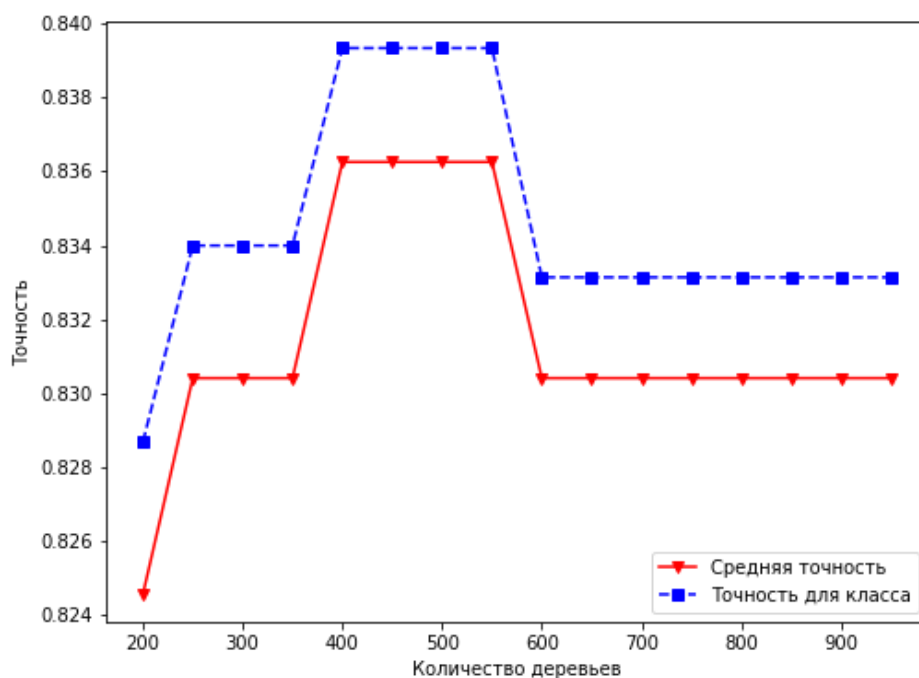


Рисунок 4.8. График зависимости точности от количества деревьев в модели.

Как можно видеть из последнего графика (рис. 4.8) максимальная точность которую удалось достичь в результате перебора гиперпараметров получилась 83,6%, что на 5% больше при использовании стандартных настроек,

при прочих равных. Таким образом лучшая модель имеет следующие параметры:

1. Количество решающих деревьев (n_estimators) — 500
2. Максимальная глубина (max_depth) — 3
3. Скорость обучения (learning_rate) — 0.86
4. Функция потерь (loss_function) — MultiClass (см. табл. 4.4)
5. Коэффициент L2 регуляризации (l2_leaf_reg) — 1.6

Для более тщательного анализа результатов предсказаний обратимся к матрице несоответствий построенной по результатам предсказаний лучшей модели (табл. 4.7).

Таблица 4.7. Матрица несоответствий для лучшей модели градиентного бустинга.

		Предсказанное значение		
		0% < Кп <= 8%	8% < Кп <= 20%	Кп > 20%
Истинное значение	0% < Кп <= 8%	43	7	0
	8% < Кп <= 20%	1	64	11
	Кп > 20%	0	9	36

Как видно из матрицы несоответствий (табл. 4.7) градиентный бустинг намного успешнее разделяет режимы с $Кп > 20\%$ от режимов с $Кп < 20\%$, в отличие от наивного Байесовского классификатора (НБК) он правильно определил 36 из 45 режимов, когда Байесовский классификатор определил правильно только 14 из 45, так же видно что средняя ошибка по каждому классу для градиентного бустинга меньше, чем для НБК, однако недостатком данной модели является меньшая точность в определении самого потенциально опасного режима с $Кп < 8\%$, данная модель не смогла определить 7 подобных режимов.

3 Обучение моделей на сырых данных

При работе с сигналами на практике очень хорошо себя показывают искусственные нейронные сети (ИНС). В качестве входных значений в ИНС передают дискретный сигнал с постоянной степенью дискретизации, таким

образом нейросеть может исследовать сигнал целиком и строить сложные зависимости на базе множества параметров сигнала. В данной главе будут рассмотрены простейшие многослойные полносвязные ИНС с функцией обратного распространения ошибки. Исходя из всего вышесказанного можно разбить структуру нейросети на три части:

1. Входной слой — количество дискретных значений описывающих сигнал для каждой измеряемой величины (200 значений * 3 сигнала = 600 входных нейронов). Можно представить как односвязные нейроны с линейной функцией активации, которые принимают на вход значение сигнала в определенный момент времени и передают его в скрытые слои ИНС.
2. Скрытые слои — слои которые будут «обучаться» (подстраиваться) по входным данным чтобы отнести режим к одному из классов. Представляют из себя полносвязные нейроны с нелинейной функцией активации. В скрытых слоях в качестве функции активации используется ReLU:

$$f(x) = \max(0, x)$$

3. Выходной — слой который выдает вероятность принадлежности режима к одному из трех классов. Для многоклассовой классификации принято использовать функцию активации softmax:

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}}$$

где z_i — выходное значение i -ого нейрона, K — количество нейронов в слое.

В качестве функции потерь (стоимости) было решено использовать перекрёсную функцию логарифмических потерь:

$$L(y, \hat{y}) = - \sum_{j=0}^M \sum_{i=0}^N (y_{ij} * \log(\hat{y}_{ij}))$$

где M — количество экземпляров, N — количество тренировочных экземпляров, y — истинная вероятность принадлежности к классу j , \hat{y} — предсказанная вероятность принадлежности к классу j .

После выбора основной архитектуры и типа нейросети можно переходить к подбору такой конфигурации, которая позволит решать задачу классификации наилучшим образом. Для поиска лучшей конфигурации варьировались следующие параметры конфигурации ИНС:

1. Количество скрытых слоев — слои в которых будет происходить вычисление принадлежности экземпляра к классу. Чем больше скрытых слоев, тем более сложные зависимости может строить нейросеть, однако большая глубина требует большего времени обучения и не может гарантировать лучшего результата.
2. Количество нейронов в скрытом слое — с увеличением количества скрытых нейронов увеличивается сложность нейросети и длительность обучения, слишком большое количество может привести к недообучению ИНС.
3. Регуляризация — позволяет контролировать переобучения, в ИНС очень популярен метод дропаут, который на этапе обучения отключает часть нейронов в слое, что заставляет оставшиеся нейроны обучаться более эффективнее.

На рисунке 4.9 приведен график зависимости точности от количества нейронов в первом слое, для нейросети с одним скрытым слоем, как видно на графике точность предсказаний очень сильно изменяется в зависимости от количества нейронов в слое, что может быть связано с правильно подобранной архитектурой, либо, что более вероятно, с переобучением, т. е. несколько архитектур хорошо подходят для предсказания тестовой выборки но не обладают достаточной обобщающей способностью. Ввиду вышесказанного

такие результаты нельзя назвать достаточным решением задачи, хотя точность и достигает почти 80%, поэтому следующим этапом добавим еще один скрытый слой с регуляризацией, для избежания переобучения и посмотрим на график точности в зависимости от изменения количества нейронов. Регуляризация была добавлена по причине того, что обучающая выборка состоит из данных одного генератора, а следовательно не может считаться репрезентативной, поэтому добавление регуляризации это попытка заставить модель вычленить общую закономерность из представленных данных.

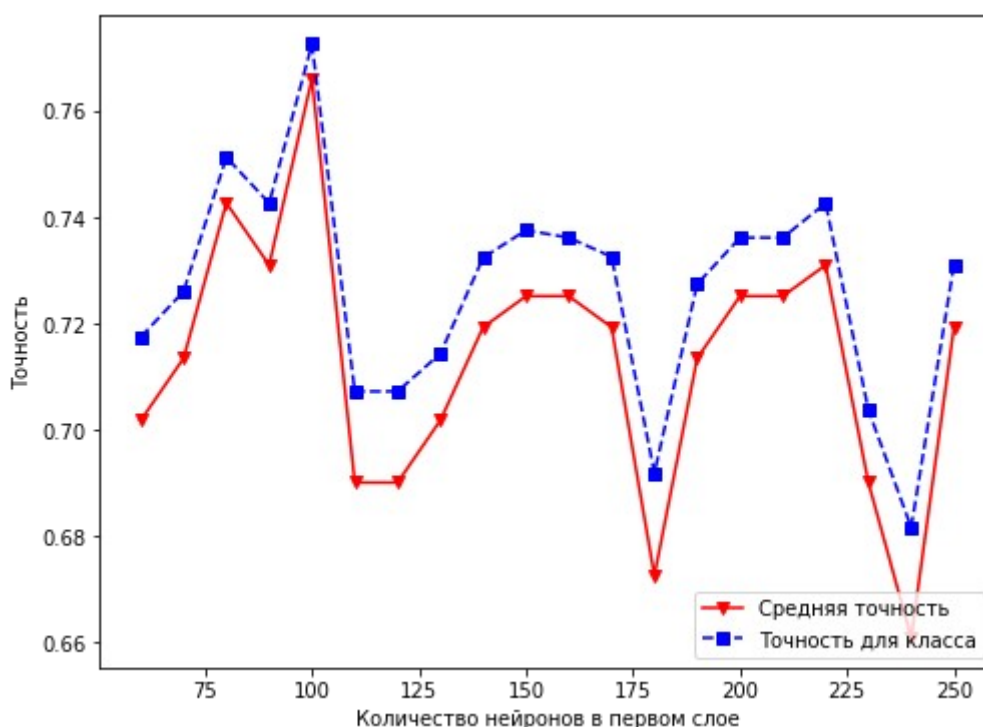


Рисунок 4.9. График зависимости точности предсказаний от количества нейронов в первом скрытом слое для ИНС с одним скрытым слоем.

Были протестированы модели с тремя скрытыми слоями, однако они не дали особого выигрыша в точности, но время обучения увеличилось в два раза, это связано с тем, что при обучении имеется ограниченный набор данных, который является сравнительно небольшим для использования глубокого обучения, поэтому использование моделей с глубиной более 2 слоев является нецелесообразной тратой времени и вычислительных мощностей.

Лучший результат, которого удалось достичь используя нейросеть составил %, результаты предсказаний на тестовой выборке представлены в виде таблицы несоответствий (табл. 4.8). Конфигурация лучшей модели:

1. Входной слой — 600 односвязных нейронов, каждый из которых передает в ИНС значение сигнала в определенный момент времени.
2. Первый скрытый слой — 190 полносвязных нейронов с функцией активации ReLU.
3. Второй скрытый слой — 120 полносвязных нейронов с функцией активации ReLU и дропаутом с вероятностью отключения каждого нейрона 0.3.

4. Выходной слой — 3 полносвязных нейрона с функцией активации Softmax (экспоненциальный максимум), каждый из которых возвращает вероятность принадлежности к классу.

Таблица 4.8. Матрица несоответствий по предсказаниям на тестовой выборке для лучшей модели ИНС.

Как видно из таблицы несоответствий (табл. 4.8) в отличие от моделей из прошлого раздела, которые обучались на табличных данных, ИНС лучше справляется с определением аварийных режимов ($K_p < 8\%$), с минимальной погрешностью (1 режим неопределен и 2 режима с $K_p > 8\%$ классифицированы ошибочно). Но как и прошлые модели ИНС путает режимы с $K_p > 8\%$, что как уже говорилось ранее является следствием условности границы, решением данной проблемы может быть сбор большего количества данных для обучающей выборке.

Несмотря на высокую точность, нельзя однозначно сказать о решаемости задачи, так как в подобных задачах очень важно правильно обозначить цель предсказания, должны ли мы отдавать большие предпочтения в предсказании режимов с более низким запасом статической устойчивости по активной мощности с потерей точности в отношении прочих сигналов или следует уменьшать ошибку предсказания режима с $8\% < K_p \leq 20\%$ как режима с $K_p < 8\%$. Но что можно сказать точно, что переходный процесс однозначно содержит информацию о значении коэффициента запаса по активной мощности.

В результате

5 ВЛИЯНИЕ НЕУСТОЙЧИВОСТИ СИСТЕМЫ НА ЦЕНУ В ОТДЕЛЬНЫХ УЗЛАХ

2 Формирование узловых цен в ЕНЭС

На рынке электроэнергии обеспечивается спрос на потребление электроэнергии с наиболее эффективной загрузкой электрических станций на основе реализуемых режимов электрической системы. Участниками рынка являются крупные поставщики и покупатели электрической энергии и мощности. К поставщикам относятся владельцы (арендаторы) генерирующего оборудования установленной мощностью не менее 5 МВт. К покупателям относятся энергосбытовые и энергоснабжающие организации, крупные потребители с присоединенной мощностью не менее 20 МВА. Организации, осуществляющие импортно-экспортные операции, являются одновременно и поставщиками, и покупателями электроэнергии и мощности.

На оптовом рынке электроэнергии в России принята узловая модель ценообразования, в соответствии с которой цена на электроэнергию определяется в каждом узле электрической системы в двустороннем узловом аукционе. Расчет узловых цен проводится в ходе оптимизации режима электрической системы по ценовым заявкам участников рынка. При отборе ценовых заявок приоритет отдается наиболее дешевым заявкам поставщиков и наиболее дорогим заявкам покупателей. Покупатели в основном подают так называемые *ценопринимаящие заявки*, в которых они выражают готовность купить электроэнергию по любой цене. Подача такой заявки отражает неэластичный спрос на электроэнергию.

Поэтому покупатели в меньшей мере участвуют в формировании цены на рынке электроэнергии, чем поставщики, у которых цена в заявке отражает топливную составляющую себестоимости производства электроэнергии. Равновесная цена на рынке формируется последней (замыкающей) —

ценообразующей — заявкой поставщика или покупателя, отобранной в ходе оптимизации.

Узловые цены на электроэнергию формируются по одной или несколькими ценообразующим заявкам под влиянием ограничений задачи оптимизации. В России оптимизация проводится для электрической системы из примерно 8600 узлов и для каждого часа на рынке на сутки вперед и балансирующем рынке определяются около 8600 узловых равновесных цен и индикаторов балансирующего рынка. Для каждого участника складывающиеся цены различны.

Для целей выделения факторов, повлиявших на различие узловых цен, используется выделение из узловых цен их компонент. Наиболее часто выделяют такие компоненты как:

- системная цена,
- цена потерь и
- системных ограничений

ВЫВОДЫ

В магистерской диссертации была выявлена потребность в разработке и исследовании новых методов для контроля режимных параметров с использованием векторных измерений (СВИ).

Выявлена тенденция использование методов машинного обучения для автоматизации и роботизации промышленных процессов, в том числе и электроэнергетики, уже активно исследуются и разрабатываются различные системы контроля устойчивости, базирующиеся на векторных измерениях и методах машинного обучения.

Была смоделирована простейшая ЭЭС, на которой были смоделированы режимы с различными конфигурациями и различными значениями Кп.

Данные смоделированных режимов были преобразованы и приведены к единому формату, после чего были сигналы были преобразованы с использованием специального программного пакета для работы с сигналами tsfresh.

На обработанных данных было протестировано множество моделей, как простых линейных, так и сложных ансамблевых. Лучшую производительность на преобразованных данных показал алгоритм градиентного бустинга над решающими деревьями и удалось достичь точности в 83,6%, однако данный классификатор испытывал проблемы классификацией режимов с $K_p < 8\%$, поэтому было решено опробовать нейросети для работы с сырыми данными.

Была подобрана конфигурация нейросети, которая дала точность предсказаний 83% и отлично справлялась с классификацией аварийных режимов, нивелируя таким образом недостатки табличных моделей.

В результате проведенных исследований можно однозначно сказать что сигналы переходного процесса содержат в себе информацию о коэффициенте запаса статической устойчивости по активной мощности, так как точность предсказаний моделей достигает 80%.

Было рассчитано влияние неустойчивости системы на узловые цены на электроэнергию и потенциальная экономическая ценность от внедрения разработанных моделей, при условии их установки в узле.

Список источников:

1. Е. И. Ушаков Статическое устойчивое электрических систем. Под ред Ю. Н. Руденко Новосибирск, Наука, 1988, 272с
2. Рахмонов, Ф. Н. Исследование статической устойчивости Навоийской ТЭС методом функций Ляпунова в квадратичной форме / Ф. Н. Рахмонов, А. А. Хамзаев, М. Ф. Истамов. — Текст : непосредственный, электронный // Молодой ученый. — 2017. — № 43 (177). — С. 58-65. — URL: <https://moluch.ru/archive/177/46094/>
3. Мария Шиллер Дисер
4. <http://isem.irk.ru/upload/iblock/946/9463eda4b708fa1a696bfc6ad3b4e4cc.pdf>
ИИ в энергетике
5. Веников, В. А. Переходные электромеханические процессы в электрических системах / В. А. Веников. – М.: Высшая школа, 1985. – 536 с.
6. Жданов, П.С. Вопросы устойчивости электрических систем / П.С. Жданов. – М.: Энергия, 1979. – 456 с. : ил.
7. Методические указания по устойчивости энергосистем. [утв. Приказом Минэнерго России от 30.06.2003 No277] [Электронный ресурс]. – Режим доступа:
http://www.so-ups.ru/fileadmin/files/laws/regulations/Metod_uk_ust.pdf
8. Развитие технологии синхронизированных векторных измерений в ЕЭС России <http://digitalsubstation.com/blog/2018/03/22/razvitie-tehnologii-sinhronizirovannyh-vektornyh-izmerenij-v-ees-rossii/>
9. Аюев Б. И. О системе мониторинга переходных режимов // Энергорынок. № 2. 2006.
10. Гайдамакин, Ф.Н. Выявление источника низкочастотных колебаний в Единой энергосистеме России / Ф.Н. Гайдамакин, А.А. Кисловский, Р.П. Теплоухов, М.А. Эдлин// Известия НТЦ Единой энергетической системы No1(70) 2014 – Спб., 2014 С.44-50
11. <https://publications.hse.ru/mirror/pubs/share/folder/8yhvx1d91h/direct/167677940>
12. www.machinelearning.ru/wiki

13. Wehenkel L. Machine learning approaches to power-system security assessment // IEEE Expert. 1997.Sep.Vol.12, No.5. Pp.6072.
https://www.researchgate.net/publication/3282075_Machine_learning_approaches_to_power-system_security_assessment/link/0a85e53a01b642265b000000/download
14. Курбацкий В.Г., Томин Н.В. Мониторинг и оценка режимной надёжности ЭЭС на базе алгоритмов машинного обучения // Сб. науч. тр. междунар. науч. семин. им. Ю. Н. Руденко "Методические вопросы исследования надёжности больших систем энергетики": Вып. 65. «Надёжность либерализованных систем энергетики». – Иркутск: ИСЭМ СО РАН. – 2015. С.535-545.
15. Improving power system monitoring and control in Russian modern megapolises / N.Voropai, V.Kurbatsky, N.Tomin, D.Panasetsky // 2016 18th Mediterranean Electrotechnical Conference (MELECON). - 2016. - April. - Pp. 1-6.
16. <https://cyberleninka.ru/article/n/sravnenie-funktsionalnyh-vozmozhnostey-suschestvuyuschih-programmnyh-sredstv-rascheta-i-analiza-elektricheskikh-rezhimov>
17. "The Machine Learning Dictionary". www.cse.unsw.edu.au. Archived from the original on 26 August 2018. Retrieved 4 November 2009.